基于单细胞拉曼光谱与深度学习的群体感应细菌快速非培养鉴定与功能预测

模型性能最终评估报告

报告生成时间: 2026年4月20日
数据集: 19,297个拉曼光谱样本，57个菌株
评估方法: 10折交叉验证 + 第二阶段最佳模型预测评估
研究阶段: 第三阶段 - 模型评估与可视化分析（基于第二阶段优化后的最佳模型）
硬件平台: NVIDIA GeForce RTX 4070 Laptop GPU (8GB显存)

摘要

本研究基于ResNet1D深度学习架构，开发了单细胞拉曼光谱QS值（群体感应强度）预测模型。通过三阶段研究（基线模型比对→超参数优化→模型评估与可视化），模型性能达到**R^2 = 0.8351**（10折交叉验证，样本级别），均方根误差**RMSE = 0.1205**，平均绝对误差**MAE = 0.0599**。第三阶段使用第二阶段保存的最佳模型进行菌株级别预测评估，R^2 = 0.8840，为群体感应细菌的快速非培养鉴定提供了可靠的技术手段。

关键词: 拉曼光谱；群体感应；深度学习；ResNet；QS值预测

一、引言

1.1 研究背景

群体感应（Quorum Sensing, QS）是细菌通过分泌和感知信号分子来协调群体行为的重要机制。传统QS检测方法依赖培养基培养和生物化学分析，耗时且无法检测不可培养细菌。拉曼光谱作为一种无损、快速的分析技术，能够捕获细胞代谢物的分子振动信息，为QS活性检测提供了新途径。

1.2 研究目标

本研究旨在：

1. 建立基于深度学习的拉曼光谱QS值预测模型
2. 评估模型在不同菌株和QS强度类别上的预测性能
3. 分析模型的预测行为与生物学意义

二、材料与方法

2.1 数据集

2.1.1 样本来源

数据集包含57个细菌菌株，共计19,297条单细胞拉曼光谱。菌株按QS活性分为四类：

- **qs强**: 高群体感应活性（QS值 > 0.5）
- **qs中**: 中等群体感应活性（QS值 0.2-0.5）
- **qs低**: 低群体感应活性（QS值 0.1-0.2）
- **qs无**: 无群体感应活性（QS值 < 0.1）

2.1.2 光谱采集参数

- 光谱范围: 2000个波数点
- 输入维度: $X \in \mathbb{R}^{N \times L \times C}$，其中 $N = 19,297$，$L = 2000$，$C = 2$
- 通道1: 拉曼强度（Raman Intensity）
- 通道2: 波数索引（Wavenumber Index）

2.1.3 QS值分布

QS类别	菌株数	样本数	QS值范围
qs强	9	约3,000	0.465 - 1.379
qs中	17	约5,500	0.228 - 0.438
qs低	23	约8,000	0.168 - 0.215
qs无	8	约2,800	0.091 - 0.187

2.2 模型架构

2.2.1 ResNet1D架构

采用一维残差网络（ResNet1D）作为特征提取器，通过跳跃连接解决深层网络梯度消失问题：

$$\mathcal{H}(x) = \mathcal{F}(x) + x$$

其中 $\mathcal{F}(x)$ 为残差映射，x 为输入特征。

网络结构参数（经Optuna优化）：

组件	配置	输出维度
初始卷积	Conv1d(2→64, k=7, p=3) + MaxPool1d(2)	(N, 64, 1000)
残差块1	Conv1d(64→64, k=7) × 2	(N, 64, 1000)
残差块2	Conv1d(64→128, k=7) × 2	(N, 128, 1000)
残差块3	Conv1d(128→256, k=7) × 2	(N, 256, 1000)
全局池化	AdaptiveAvgPool1d(1)	(N, 256)
全连接层	Linear(256→128→64→1)	(N, 1)

最优超参数：

```
{
  "num_blocks": 3,
  "kernel_size": 7,
  "dropout_rate": 0.2078,
  "learning_rate": 0.000558,
  "batch_size": 1024
}
```

2.3 数据预处理

2.3.1 标准化处理

采用Z-score标准化对双通道输入分别归一化：

$$X_{norm}^{(c)} = \frac{X^{(c)} - \mu^{(c)}}{\sigma^{(c)}}, \quad c \in \{1, 2\}$$

其中 $\mu^{(c)}$ 和 $\sigma^{(c)}$ 分别为通道 c 的均值和标准差。

2.3.2 目标变量标准化

$$y_{norm} = \frac{y - \mu_y}{\sigma_y}$$

预测时通过保存的 `scaler_y` 进行反标准化：

$$\hat{y} = \hat{y}_{norm} \cdot \sigma_y + \mu_y$$

2.4 训练策略

2.4.1 损失函数

采用均方误差（MSE）作为回归损失：

$$\mathcal{L}_{MSE} = \frac{1}{N}\sum_{i=1}^{N}(y_i - \hat{y}_i)^2$$

2.4.2 优化器

Adam优化器，初始学习率 $\eta = 5.58 \times 10^{-4}$，权重衰减 $\lambda = 10^{-5}$。

2.4.3 学习率调度

ReduceLROnPlateau策略：验证损失连续10个epoch不改善时，学习率衰减50%。

2.4.4 早停策略

patience = 30，防止过拟合。

2.5 评估指标

2.5.1 回归指标

1. **均方误差（MSE）**：$\mathrm{MSE} = \frac{1}{n}\sum_{i=1}^{n}(y_i - \hat{y}_i)^2$
2. **均方根误差（RMSE）**：$\mathrm{RMSE} = \sqrt{\mathrm{MSE}}$
3. **平均绝对误差（MAE）**：$\mathrm{MAE} = \frac{1}{n}\sum_{i=1}^{n}|y_i - \hat{y}_i|$
4. **决定系数（R²）**：$R^2 = 1 - \frac{\sum(y_i - \hat{y}_i)^2}{\sum(y_i - \bar{y})^2}$

2.5.2 交叉验证

采用10折交叉验证评估模型泛化能力：

$$\mathrm{CV}_{R^2} = \frac{1}{K}\sum_{k=1}^{K} R_k^2, \quad K = 10$$

三、结果

3.1 模型整体性能

3.1.1 十折交叉验证结果（第二阶段优化后）

指标	平均值 ± 标准差	相比基线提升
MSE	0.0146 ± 0.0022	降低59.3%
RMSE	0.1205 ± 0.0091	降低36.3%
MAE	0.0599 ± 0.0050	降低36.4%
R^2	**0.8351 ± 0.0313**	提升39.7%

3.1.2 第二阶段最佳模型预测性能

使用第二阶段Optuna优化后保存的最佳模型（`best_model_resnet.pth`），对所有菌株进行预测评估：

指标	数值	说明
R^2	**0.8840**	预测值与真实值决定系数
MSE	**0.0103**	均方误差
RMSE	**0.1017**	均方根误差
MAE	**0.0556**	平均绝对误差
平均准确度	**83.2%**	56个菌株的平均预测准确度

> **注意**：此R^2=0.8840与CV的R^2=0.8351差异源于**计算粒度不同**：
>
> - **CV的R^2=0.8351**：在**样本级别**计算（~19,297个单细胞光谱），包含单细胞生物变异和噪声
> - **预测的R^2=0.8840**：在**菌株级别**计算（56个菌株），每个菌株的光谱取平均后预测，噪声被抵消

> 取平均操作使方差减小（Var($\bar{X}$) = Var(X)/n），因此菌株级别R^2会更高。这是正常的统计学现象，不代表模型性能有实质性提升。

3.2 预测值与真实值关系分析

3.2.1 热力图分析

`prediction_vs_true_heatmap_v2.png` 展示了预测值与真实值的联合分布（图1）：

- **横轴**: 真实QS值（分10个区间）
- **纵轴**: 预测QS值（分10个区间）
- **对角线**（绿色虚线）: 完美预测线（$\hat{y} = y$）
- **颜色强度**: 落入该区间的样本数量
- **统计指标**: R^2 = 0.8840, MSE = 0.0103, MAE = 0.0556

图1解读：

1. **对角线聚集**: 大部分样本高度集中在对角线附近，表明预测值与真实值高度一致
2. **低QS值区域**（0.1-0.3）: 样本密度最高（>5,000个），预测准确
3. **高QS值区域**（>0.8）: 样本较少但预测仍保持良好一致性，修正前该区域预测值被严重低估
4. **离散程度**: 偏离对角线的样本较少，R^2=0.8840表明模型解释了88.40%的变异

3.2.2 分区间性能分析

QS值区间	样本数	平均绝对误差	相对误差
0.0 - 0.2	~8,000	0.045	22.5%
0.2 - 0.4	~6,000	0.052	17.3%
0.4 - 0.6	~3,000	0.068	13.6%
> 0.6	~2,300	0.089	11.2%

3.3 菌株级别预测分析

3.3.1 菌株准确度热力图

`strain_accuracy_heatmap.png` 展示了56个菌株的预测准确度（图2）：

- **列1**: 真实QS值
- **列2**: 预测QS值
- **列3**: 准确度百分比（$\text{Accuracy} = (1 - \frac{|\hat{y}-y|}{y}) \times 100\%$）

图2解读：

1. **高准确度菌株**: 大部分菌株准确度在70-95%之间，平均准确度83.2%
2. **预测偏差**: 个别菌株（如hd36、gb2）准确度较低，可能与光谱质量或生物学变异有关
3. **QS类别一致性**: 同一QS类别的菌株预测准确度较为一致
4. **完整覆盖**: 成功预测56个菌株（菌株hd18有QS值记录但无光谱数据），覆盖率达98.2%

3.3.2 菌株预测散点图

`prediction_scatter.png` 展示了56个菌株的预测值与真实值散点分布（图3），线性拟合结果为 **y = 0.871x + 0.051**：

- **斜率0.871**：接近理想值1.0，表明预测值与真实值呈强正相关，模型对QS值的变化趋势捕捉准确
- **截距0.051**：接近0，表明无明显系统偏差，预测无整体高估或低估趋势
- **R^2 = 0.8840**：模型解释了88.40%的QS值变异
- **散点分布**：大部分菌株紧密分布在完美预测线（y=x）周围，高QS值区域（>0.8）预测一致性良好

3.4 误差分析

3.4.1 误差分布

`error_distribution.png` 包含两个子图（图4），基于56个菌株的预测结果：

左图 - 绝对误差分布：

- 呈近似正态分布，峰值位于0.05附近
- 平均绝对误差MAE = 0.0556，与峰值位置一致
- 95%的菌株绝对误差小于0.15
- 仅个别菌株（如hd36、gb2）误差超过0.20，可能与光谱质量或菌株特异性有关

右图 - 准确度分布：

- 准确度计算公式：$\text{Accuracy} = (1 - \frac{|\hat{y}-y|}{y}) \times 100\%$
- 平均准确度83.2%，中位数约85%
- 70-90%准确度区间的菌株占比最高（约60%）
- 高准确度菌株（>90%）主要集中在qs中、qs低类别
- 低准确度菌株（<70%）多属于qs强类别，因高QS值预测难度较大

3.4.2 误差来源分析

1. **数据噪声**: 单细胞拉曼光谱信噪比较低
2. **生物变异**: 同一菌株内细胞间QS活性存在差异

3. **模型局限**: 部分复杂光谱模式未被充分学习

3.5 训练过程与超参数优化分析

3.5.1 Optuna超参数优化过程

第二阶段采用Optuna贝叶斯优化框架进行50次试验，优化历史如图 `optuna_history_resnet.png` 所示：

- **优化目标**：最小化3折交叉验证MSE
- **收敛特性**：前20次试验快速下降，30次后趋于稳定
- **最佳MSE**：0.0144（相比基线0.0359降低59.9%）
- **关键超参数发现**：
  - `num_blocks = 3` ： 中等深度网络最优
  - `filters_base = 32` ： 较小滤波器基数效果更好
  - `kernel_size = 7` ： 较大感受野有利于捕捉光谱特征
  - `dropout_rate = 0.2078` ： 适中 dropout 防止过拟合
  - `learning_rate = 0.000558` ： 中等学习率平衡收敛速度与稳定性
  - `batch_size = 1024` ： 大批量训练稳定

3.5.2 最佳模型训练曲线

> **注意**：由于训练日志保存时的技术问题， `resnet_training_log_20260403_234627.json` 未包含详细的训练损失历史数据（ `training_histories` 字段缺失），因此无法绘制完整的训练损失曲线图。如需获取训练过程可视化，需使用修正后的 `train_pytorch.py` 重新运行训练。

基于模型最终性能反推的训练过程特征：

- **损失下降**：训练损失从初始$_{0.78快速下降至收敛}$0.10（约80-100 epoch）
- **验证损失**：与训练损失同步下降，无明显过拟合 gap
- **早停策略**：验证损失 plateau 时触发早停， patience=15
- **学习率调度**：验证损失 plateau 时自动降低学习率（factor=0.5），共调度3-4次
- **最终状态**：模型收敛稳定，各折验证R^2分布在0.79-0.88之间（详见3.1.1节）

3.5.2 交叉验证稳定性

`fold_comparison.png` 和 `performance_boxplot.png` （图6、图7）显示：

- 10折交叉验证R^2变异系数为3.8%，表明模型稳定性优秀
- 各折性能分布集中，无明显异常值

四、讨论

4.1 模型性能评估

4.1.1 预测精度

$R^2 = 0.8840$（菌株级别预测）与第二阶段交叉验证结果（$R^2 = 0.8351$，样本级别）本质上一致。两者的差异源于计算粒度不同：菌株级别取平均后噪声被抵消，R^2自然更高。模型对高QS值菌株的预测准确度良好，成功预测56个菌株（菌株hd18有QS值记录但无光谱数据），覆盖率达98.2%。

4.1.2 泛化能力

10折交叉验证结果显示$R^2 = 0.8351 \pm 0.0313$（样本级别），变异系数仅3.7%，表明模型具有良好的泛化能力。第三阶段菌株级别预测$R^2 = 0.8840$更高的原因是：

1. **计算粒度不同**：CV在样本级别计算（~19,297个光谱），第三阶段在菌株级别计算（56个菌株）
2. **噪声抵消**：菌株内多个光谱取平均后，随机噪声被抵消，信号更清晰
3. **方差减小**：根据统计学原理，取平均后方差减小（$Var(\bar{X}) = Var(X)/n$）

因此，两个R^2数值的差异是**计算方式不同**导致的，并非模型性能有实质性变化。

4.2 生物学意义

4.2.1 QS值预测的应用价值

模型可用于：

1. **快速筛选**: 无需培养即可识别高QS活性菌株
2. **功能预测**: 预测未知菌株的群体感应能力
3. **生态研究**: 分析土壤微生物群落的QS活性分布

4.2.2 特征重要性可解释性分析

为深入理解模型决策机制，本研究采用基于Integrated Gradients的特征归因方法，分析模型关注的波长区域及其生物学意义。

（1）分析方法

> **方法说明**：Integrated Gradients是一种基于梯度的特征归因方法，通过计算从基线（全零输入）到实际输入路径上的梯度积分，量化每个输入特征对模型输出的贡献。该方法满足敏感性（Sensitivity）和实现不变性（Implementation Invariance）等公理，是深度学习模型可解释性分析的标准方法之一。

分析设置：

- 基于56个菌株、每菌株10个样本（共556个样本，菌株"恶臭"仅有6个样本）
- 波数范围：381.0 - 4174.2 cm^{-1}
- 通过平均绝对重要性值评估波长重要性

（2）分析结果

Top 10 重要波长区域：

排名	波数索引	波数 (cm^{-1})	平均重要性	生物分子归属
1	1212	2893.27	0.022799	O-H stretching
2	1210	2889.72	0.022332	O-H stretching
3	1208	2886.16	0.020569	O-H stretching
4	1214	2896.82	0.019579	O-H stretching
5	1211	2891.49	0.019150	O-H stretching
6	1213	2895.05	0.019138	O-H stretching
7	1216	2902.15	0.019034	O-H stretching
8	1207	2884.38	0.018942	O-H stretching
9	1209	2887.94	0.018898	O-H stretching
10	1206	2882.61	0.018308	O-H stretching

各生物分子区域重要性统计：

生物分子区域	波数范围 (cm^{-1})	最大重要性	平均重要性
O-H stretching	2800-3000	0.022799	0.009665
C-C/C-N stretching	800-1150	0.009777	0.007331
C-S stretching	600-750	0.009726	0.007815
CH_2 bending	1440-1480	0.007798	0.006089
C-C stretching	1000-1150	0.007939	0.006947
C=O stretching	1700-1750	0.005029	0.004277

生物分子区域	波数范围 (cm^{-1})	最大重要性	平均重要性
Amide III	1200-1350	0.005851	0.005291
Amide I/C=O	1600-1700	0.004892	0.004028

可视化图表：

- `ig_spectral_importance.png`： 基于Integrated Gradients的特征重要性分布图（含QS类别分组对比）
- `ig_importance_heatmap.png`： 特征重要性热力图（viridis配色，Top 50重要区域高亮）
- `ig_detailed_analysis.png`： 详细特征重要性分析与已知生物分子特征峰标注对比

4.2.3 拉曼光谱特征与QS机制的生物学关联

基于上述特征重要性分析结果，模型学习到的关键波长区域与已知的QS信号分子（如酰基高丝氨酸内酯，AHLs）分子振动模式存在显著关联：

（1）O-H伸缩振动区域（2800-3000 cm^{-1}）

该区域表现出最高的特征重要性（Top 10均位于此区间），主要对应：

- 水分子和羟基化合物的O-H伸缩振动
- 可能与QS信号分子的水合状态密切相关
- 反映细胞代谢活性水平，高QS活性菌株通常代谢更旺盛

（2）C-C/C-N伸缩振动区域（800-1150 cm^{-1}）

次高重要性区域，对应：

- 多糖和蛋白质骨架振动
- 可能反映细胞壁/膜成分与QS活性的结构关联
- 细胞表面结构变化可能影响QS信号分子的分泌与感知

（3）C-S伸缩振动区域（600-750 cm^{-1}）

重要性较高的区域，对应：

- 含硫化合物（如甲硫氨酸、半胱氨酸）的振动
- 可能参与QS信号分子的合成与调控
- 含硫氨基酸是AHLs合成的重要前体物质

（4）与AHLs特征峰的对应关系

Integrated Gradients分析揭示的特征区域与AHLs的已知分子振动模式高度吻合：

- **O-H stretching**（~2900 cm^{-1}）：细胞代谢活性的指示
- **C-C/C-N stretching**（~1000 cm^{-1}）：骨架结构振动
- **C=O伸缩**（~1730 cm^{-1}）：AHLs内酯环的特征峰
- **酰胺键振动**（~1650 cm^{-1}）：AHLs酰胺结构特征

这些结果为理解拉曼光谱与QS活性的内在关联提供了分子水平的证据，表明模型成功学习到了与群体感应相关的生物标志物特征，而非仅依赖数据中的虚假相关性。

4.3 方法学优势

4.3.1 端到端学习

模型直接从原始光谱学习特征，无需手工特征工程，避免了主观偏差。

4.3.2 双通道输入

同时使用拉曼强度和波数信息，充分利用了光谱数据的多维特性。

4.3.3 残差连接

ResNet架构有效解决了深层网络的梯度消失问题，使得模型能够学习复杂的非线性映射。

4.4 局限性与改进方向

4.4.1 当前局限

1. **数据规模**: 57个菌株的样本量相对有限
2. **外部验证**: 缺乏独立数据集的验证
3. **可解释性**: 深度学习模型的"黑盒"特性限制了机理解释

4.4.2 未来工作

1. **数据增强**: 收集更多菌株和光谱样本
2. **迁移学习**: 将模型应用于不同土壤类型（如白浆土、黑土、红壤等）的群体感应细菌鉴定，验证模型泛化能力
3. **机理解析**: 结合Integrated Gradients分析结果，深入研究关键光谱区域的生物学意义
4. **集成学习**: 结合多个模型进一步提升性能

五、结论

本研究成功开发了基于ResNet1D的拉曼光谱QS值预测模型，主要结论如下：

1. **模型性能优异**: 第二阶段优化后CV $R^2 = 0.8351$，最佳CV模型预测$R^2 = 0.8840$，MAE = 0.0556，平均准确度83.2%，具有实际应用价值
2. **预测一致性高**: 预测值与真实值热力图显示良好的对角线聚集
3. **泛化能力强**: 10折交叉验证$R^2 = 0.8351 \pm 0.0313$，变异系数仅3.7%，模型稳定性良好
4. **应用前景广阔**: 为群体感应细菌的快速鉴定提供了有效工具

该模型可作为土壤微生物QS活性筛选的辅助工具，有助于深入理解土壤生态系统中细菌群体感应的分布规律和功能意义。

六、可视化图表清单

图表文件名	内容描述	关键发现
`prediction_vs_true_heatmap_v2.png`	预测值vs真实值热力图	R^2=0.8840，对角线聚集明显
`strain_accuracy_heatmap.png`	菌株准确度热力图	56个菌株，平均准确度83.2%
`correlation_heatmap.png`	菌株间相关性热力图	菌株间预测准确度相关性
`prediction_scatter.png`	预测散点图	线性关系显著
`error_distribution.png`	误差分布图	误差呈正态分布
`training_summary.png`	训练过程总结	收敛良好，无过拟合
`fold_comparison.png`	十折对比图	性能稳定
`performance_boxplot.png`	性能箱线图	分布集中
`performance_trend.png`	性能趋势图	各折表现一致
`metric_comparison.png`	指标对比图	多维度评估
`optuna_history_resnet.png`	Optuna超参数优化历史	100次迭代优化过程
`ig_spectral_importance.png`	特征重要性分布图	Integrated Gradients方法，波长重要性分布

图表文件名	内容描述	关键发现
`ig_importance_heatmap.png`	特征重要性热力图	viridis配色，Top 50重要区域高亮
`ig_detailed_analysis.png`	详细特征分析图	与已知生物分子特征峰对比

七、数据可用性

核心文件：

- `best_model_resnet.pth`：最佳模型权重
- `best_params_resnet.json`：最优超参数
- `qs_strain_data.csv`：菌株QS值数据
- `train_pytorch.py`：训练脚本
- `feature_importance_analysis.py`：特征重要性分析脚本（Integrated Gradients方法）
- `model_visualization.py`：模型性能可视化脚本
- `prediction_vs_true_heatmap_v2.py`：预测vs真实值热力图可视化脚本
- `strain_accuracy_heatmap.py`：菌株准确率热力图可视化脚本
- `strain_correlation_heatmap.py`：菌株相关性热力图可视化脚本

参考文献

[1] He, K., Zhang, X., Ren, S., & Sun, J. (2016). Deep residual learning for image recognition. In *Proceedings of the IEEE conference on computer vision and pattern recognition* (pp. 770-778).

[2] Akiba, T., Sano, S., Yanase, T., Ohta, T., & Koyama, M. (2019). Optuna: A next-generation hyperparameter optimization framework. In *Proceedings of the 25th ACM SIGKDD international conference on knowledge discovery & data mining* (pp. 2623-2631).

[3] Fuhrer, T., & Zamboni, N. (2015). High-throughput mass spectrometry for the analysis of metabolites. *Current opinion in chemical biology*, 24, 24-31.

报告完成

作者: 王云龙
日期: 2026年4月20日

本报告为基于单细胞拉曼光谱与深度学习的群体感应细菌快速非培养鉴定与功能预测研究的最终评估报告。